



UNIVERSIDAD
DE GRANADA

GENERACIÓN DE DATOS SINTÉTICA A PARTIR DE UN
SISTEMA IOT DE DETECCIÓN DE VEHÍCULOS UTILIZANDO
MODELOS TRANSFORMER CON ATENCIÓN EN PYTHON

RICARDO RUIZ FERNÁNDEZ DE ALBA

Trabajo Fin de Grado

Doble Grado en Ingeniería Informática y Matemáticas

Tutores

María Bermúdez Edo

FACULTAD DE CIENCIAS

E.T.S. INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

Granada, a 30 de marzo de 2025

ÍNDICE GENERAL

1.	INTRODUCCIÓN Y OBJETIVOS	5
1.1.	Introducción	5
1.1.1.	Contextualización	5
1.1.2.	Descripción del problema	5
1.1.3.	Estructura del trabajo	6
1.1.4.	Herramientas Matemáticas e Informáticas	6
1.1.5.	Bibliografía Fundamental	7
1.2.	Objetivos	7
1.2.1.	Objetivo General	7
1.2.2.	Parte de Matemáticas Específicos	7
1.2.3.	Parte de Informática	7
2.	FUNDAMENTOS MATEMÁTICOS Y DEL APRENDIZAJE AUTOMÁTICO	8
2.1.	Fundamentos Matemáticos	8
2.1.1.	Fundamentos del Análisis	8
2.1.2.	Fundamentos de Probabilidad	8
2.2.	Teoría del Aprendizaje Estadístico	8
2.2.1.	Introducción a la Teoría del Aprendizaje	8
2.2.2.	Paradigma ERM (Empirical Risk Minimization)	8
2.3.	Optimización y Métodos de Entrenamiento	8
2.3.1.	Descenso de Gradiente Estocástico (SGD)	8
2.3.2.	Algoritmos de Optimización Avanzados	8
3.	ARQUITECTURA DEL TRANSFORMER. SAITS	9
3.1.	Modelos Transformer. Arquitectura	9
3.1.1.	Introducción a los Modelos Transformer	9
3.1.2.	Mecanismo de Atención Escalonada	9
3.1.3.	Estructura de Capas en un Transformer	9
3.1.4.	Retropropagación en Modelos Transformer	9
3.2.	Self-Attention-based Imputation for Time Series (SAITS)	9
4.	ANÁLISIS EXPLORATORIO DE LOS DATOS Y PIPELINE DE PREPROCESA- MIENTO E IMPUTACIÓN	10
4.1.	Análisis Exploratorio de Datos	10
4.2.	Preprocesamiento e Imputación	13
4.2.1.	Imputación por Mediana	13
4.2.2.	Imputación con SAITS (Pipeline - Parte 3)	13
4.3.	Evaluación de Métodos de Imputación	19
5.	CONCLUSIONES Y TRABAJO FUTURO	21
5.1.	Conclusiones	21

5.1.1.	Principales Contribuciones del Trabajo	21
5.1.2.	Impacto del Uso de Datos Sintéticos en IoT	21
5.2.	Trabajo Futuro	21
5.2.1.	Mejora de los Modelos Transformer	21
5.2.2.	Extensiones a Otros Sistemas IoT	21
5.2.3.	Posibles Aplicaciones en Diferentes Dominios	21

RESUMEN

INTRODUCCIÓN Y OBJETIVOS

1.1 INTRODUCCIÓN

1.1.1 *Contextualización*

La Inteligencia Artificial (IA), impulsada por el avance en algoritmos de aprendizaje automático ha experimentado un rápido desarrollo debido a su reciente viabilidad de ejecución en hardware y la creciente disponibilidad de datos.

Sus fundamentos matemáticos, incluyendo el análisis, la probabilidad y el álgebra lineal que conforman la teoría del aprendizaje estadístico son esenciales para construir modelos que aprenden de los datos y realizan predicciones.

Como aplicación particular se encuentra la capacidad de estos algoritmos para identificar patrones en datos generados por las tecnologías de Internet Industrial de las Cosas (IoT), basadas en redes de sensores y dispositivos conectados a Internet que recopilan y transmiten datos en tiempo real.

1.1.2 *Descripción del problema*

El marco de este trabajo está relacionado con un proyecto de investigación de un sistema IoT implementado en la región de Poqueira, en la Alpujarra granadina [Sma]. El sistema IoT ha procesado la información recogida por los sensores visuales y la ha exportado a un conjunto de datos con múltiples características.

El entrenamiento de modelos de Aprendizaje Automático a partir de estos datos podría predecir variables que mejorasen la gestión de la ocupación de la zona, promoviendo así una mayor sostenibilidad en la comunidad local.

Sin embargo, la complejidad de la información obtenida, la presencia de ruido y la falta de datos etiquetados, dificultan la tarea. En este contexto, la generación de datos sintéticos se presenta como solución, pues permite añadir al conjunto de datos

original muestras generadas artificialmente que simulan las características de los datos reales. Esta técnica facilita el entrenamiento de modelos más robustos y precisos, abordando la escasez de etiquetas y mejorando la precisión de los modelos.

Aunque la literatura existente ha utilizado diversos Modelos de Generación Profunda (DGMs), incluyendo Redes Generativas Antagónicas (GANs) y Modelos de Auto-encoders Variacionales (VAEs) [SBEXC22], en este proyecto nos centraremos en los Modelos Transformers con Atención, pues su capacidad de modelar dependencias a largo plazo en los datos, los presenta como una alternativa prometedora.

1.1.3 Estructura del trabajo

Este trabajo se organiza en cinco partes, cada una de las cuales se divide en capítulos que abordan diferentes aspectos del problema y su solución. La estructura sigue las directrices establecidas para los trabajos de fin de grado.

- **Primera parte:** Presenta la introducción y los objetivos del proyecto.
- **Segunda parte:** Detalla los fundamentos matemáticos y teóricos del aprendizaje automático que sustentan el trabajo.
- **Tercera parte:** Se centra en el análisis de los modelos Transformer y perceptrones multicapa, explorando sus fundamentos matemáticos y arquitectura.
- **Cuarta parte:** Describe el desarrollo del proyecto y los experimentos realizados, incluyendo detalles sobre el problema, el software utilizado, el preprocesamiento de datos y las métricas de evaluación.
- **Quinta parte:** Presenta las conclusiones y reflexiones finales sobre el trabajo, así como recomendaciones para futuras investigaciones.

1.1.4 Herramientas Matemáticas e Informáticas

Para el desarrollo de este trabajo se utilizarán herramientas matemáticas e informáticas clave. Los fundamentos matemáticos incluyen análisis (diferenciabilidad), probabilidad y estadística para el manejo de la incertidumbre, y álgebra lineal, esenciales en el diseño y optimización de modelos de *machine learning*.

La implementación se llevará a cabo en Python, utilizando bibliotecas como *Numpy*, *Pandas*, y *Matplotlib* para el análisis de datos, y *Pypots* para el entrenamiento de los modelos *Transformers*.

1.1.5 Bibliografía Fundamental

Para la elaboración del Capítulo 3, Teoría del Aprendizaje Estadístico se ha destacado el uso del libro Learning from Data [AMMIL12].

1.2 OBJETIVOS

1.2.1 Objetivo General

El objetivo general de este trabajo es analizar los fundamentos matemáticos del aprendizaje automático y aplicar este conocimiento en la implementación de modelos generativos, específicamente utilizando arquitecturas Transformer, para la creación de datos sintéticos aplicables en la previsión de la ocupación a partir del conjunto de datos.

1.2.2 Parte de Matemáticas Específicos

1. **Estudiar los fundamentos matemáticos del aprendizaje automático:** Revisar y comprender los conceptos matemáticos y teóricos que sustentan el aprendizaje automático, incluyendo teoría sobre cotas de generalización, optimización y regularización.

El objetivo 1 de matemáticas se abordará en el Capítulo 2.

1.2.3 Parte de Informática

1. **Definir la arquitectura Transformer** Definir el modelo de perceptrones multicapa, el mecanismo de atención y como la arquitectura transformers combina ambos.
2. **Analizar las características de los datos recopilados:** Llevar a cabo un análisis del conjunto de datos obtenidos del sistema IoT de detección de vehículos, identificando limitaciones y patrones significativos.
3. **Analizar el rendimiento del modelo Transformer:** Evaluar el rendimiento y efectividad del modelo Transformer con atención a partir de métricas de evaluación, comparándolo con otros enfoques de modelado generativo.

El objetivo 1 de Informática se abordará en el Capítulo 3, el objetivo 2 en el Capítulo 4 y el objetivo 3 en el Capítulo 5.

FUNDAMENTOS MATEMÁTICOS Y DEL APRENDIZAJE AUTOMÁTICO

2.1 FUNDAMENTOS MATEMÁTICOS

2.1.1 *Fundamentos del Análisis*

2.1.1.1 *Regla de la Cadena y su Aplicación en Modelos de Machine Learning*

2.1.2 *Fundamentos de Probabilidad*

2.2 TEORÍA DEL APRENDIZAJE ESTADÍSTICO

2.2.1 *Introducción a la Teoría del Aprendizaje*

2.2.2 *Paradigma ERM (Empirical Risk Minimization)*

2.3 OPTIMIZACIÓN Y MÉTODOS DE ENTRENAMIENTO

2.3.1 *Descenso de Gradiente Estocástico (SGD)*

2.3.2 *Algoritmos de Optimización Avanzados*

2.3.2.1 *Adam*

ARQUITECTURA DEL TRANSFORMER. SAITS

3.1 MODELOS TRANSFORMER. ARQUITECTURA

3.1.1 *Introducción a los Modelos Transformer*

3.1.2 *Mecanismo de Atención Escalonada*

3.1.2.1 *Matrices de Consulta, Clave y Valor*

3.1.2.2 *Normalización y Softmax*

3.1.3 *Estructura de Capas en un Transformer*

3.1.4 *Retropropagación en Modelos Transformer*

3.2 SELF-ATTENTION-BASED IMPUTATION FOR TIME SERIES (SAITS)

ANÁLISIS EXPLORATORIO DE LOS DATOS Y PIPELINE DE PREPROCESAMIENTO E IMPUTACIÓN

4.1 ANÁLISIS EXPLORATORIO DE DATOS

Este notebook realiza un análisis exploratorio de los datos de tráfico y emisiones contaminantes




Figura 1: Visualización de datos (Celda 16). Reemplaza esta leyenda.




Figura 2: Visualización de datos (Celda 19). Reemplaza esta leyenda.




Figura 3: Visualización de datos (Celda 20). Reemplaza esta leyenda.




Figura 4: Visualización de datos (Celda 21). Reemplaza esta leyenda.




Figura 5: Visualización de datos (Celda 22). Reemplaza esta leyenda.




Figura 6: Visualización de datos (Celda 23). Reemplaza esta leyenda.




Figura 7: Visualización de datos (Celda 25). Reemplaza esta leyenda.

4.2 PREPROCESAMIENTO E IMPUTACIÓN

En esta sección, se detallan los pasos de preprocesamiento...

4.2.1 Imputación por Mediana

Se realizó una imputación inicial utilizando la mediana...

4.2.2 Imputación con SAITS

Posteriormente, se aplicó el modelo SAITS...




Figura 8: Visualización relacionada con SAITS (Celda 33). Reemplaza esta leyenda.




Figura 9: Visualización relacionada con SAITS (Celda 34). Reemplaza esta leyenda.




Figura 10: Visualización relacionada con SAITS (Celda 35). Reemplaza esta leyenda.




Figura 11: Visualización relacionada con SAITS (Celda 37). Reemplaza esta leyenda.




Figura 12: Visualización relacionada con SAITS (Celda 38). Reemplaza esta leyenda.




Figura 13: Visualización relacionada con SAITS (Celda 39). Reemplaza esta leyenda.




Figura 14: Gráfico de evaluación (Celda 51). Reemplaza esta leyenda.




Figura 15: Gráfico de evaluación (Celda 53). Reemplaza esta leyenda.




Figura 16: Gráfico de evaluación (Celda 54). Reemplaza esta leyenda.




Figura 17: Gráfico de evaluación (Celda 56). Reemplaza esta leyenda.




Figura 18: Gráfico de evaluación (Celda 58). Reemplaza esta leyenda.




Figura 19: Gráfico de evaluación (Celda 60 - Pipeline 3). Reemplaza esta leyenda.




Figura 20: Gráfico de evaluación (Celda 62). Reemplaza esta leyenda.




Figura 21: Gráfico de evaluación (Celda 64). Reemplaza esta leyenda.




Figura 22: Gráfico de evaluación (Celda 66). Reemplaza esta leyenda.




Figura 23: Gráfico de evaluación (Celda 68). Reemplaza esta leyenda.




Figura 24: Gráfico de evaluación (Celda 70). Reemplaza esta leyenda.




Figura 25: Gráfico de evaluación (Celda 72). Reemplaza esta leyenda.

4.3 EVALUACIÓN DE MÉTODOS DE IMPUTACIÓN

Se compararon los resultados de la imputación por mediana y la imputación mediante SAITS utilizando diversas métricas de error estándar: Error Cuadrático Medio Raíz (RMSE), Error Cuadrático Medio (MSE), Error Absoluto Medio (MAE) y Error

Relativo Medio (MRE). Los valores obtenidos para el conjunto de test se resumen detalladamente en la Tabla 1. Adicionalmente, se visualizaron los resultados de la imputación en diversos gráficos (Figuras 14 a 25).

Cuadro 1: Comparación de Errores de Imputación en el conjunto de test.

Tipo de Error	Imputación por Mediana	Imputación SAITS
Root Mean Squared Error (RMSE)	0.573211	0.411882
Mean Squared Error (MSE)	0.328571	0.169647
Mean Absolute Error (MAE)	0.440679	0.369306
Mean Relative Error (MRE)	432.648363	362.576086

CONCLUSIONES Y TRABAJO FUTURO

5.1 CONCLUSIONES

5.1.1 *Principales Contribuciones del Trabajo*

5.1.2 *Impacto del Uso de Datos Sintéticos en IoT*

5.2 TRABAJO FUTURO

5.2.1 *Mejora de los Modelos Transformer*

5.2.2 *Extensiones a Otros Sistemas IoT*

5.2.3 *Posibles Aplicaciones en Diferentes Dominios*

BIBLIOGRAFÍA

- [AMMIL12] Yaser S. Abu-Mostafa, Malik Magdon-Ismail, and Hsuan-Tien Lin. *Learning From Data*. AMLBook, 2012.
- [SBEXC22] De Suparna, Maria Bermudez-Edo, Honghui Xu, and Zhipeng Cai. Deep generative models in the industrial internet of things: A survey. *IEEE Transactions on Industrial Informatics*, 18(9):5728–5737, 2022.
- [Sma] Smartpoqueira. Proyecto pionero en Europa en experimentación con tecnología inteligente para gestión sostenible de visitas a zonas rurales y parques nacionales.