

Imputación de Datos Faltantes de Variables Meteorológicas y de Contaminación en Series Temporales Multivariantes IoT con Modelos Transformer



**UNIVERSIDAD
DE GRANADA**

Ricardo Ruiz Fernández de Alba
(ricardoruiz@correo.ugr.es)

Tutores:

- María del Campo Bermúdez Edo
- Daniel Bolaños Martínez

domingo, 22 de junio de 2025



**FACULTAD
DE CIENCIAS**

Índice



I. Introducción y Caso de Estudio: Smart Poqueira.



II. Estado del Arte.



III. Fundamentos Teóricos.



IV. Arquitectura Transformer y SAITS.



V. Desarrollo de Software y Pipeline Integrado.




VI. Resultados y Discusión.



VII. Conclusiones y Futuro.

I. Introducción: Smart Poqueira



Proyecto de investigación UGR.

Infraestructura IoT:
(i), (ii), (iii), (iv)
Cámaras LPR (tráfico)

★ unidad móvil
(contaminación)

I. El Desafío de los Datos Faltantes


Al analizar los datos registrados cada hora de 114 variables.
El dataset original está constituido por dos series temporales multivariantes **parcialmente observadas**.

Periodo	Filas x Columnas	Datos Totales	Datos Obtenidos	Datos Faltantes	Porcentaje Datos faltantes
1er: 18/01/2023- 14/03/2023	1332x114	151848	108954	42894	28.3%
2do: 07/06/2023- 26/06/2023	480x114	54720	39040	15680	28.7%

Problema: 28.4% **Datos Faltantes** (missing data).

I. Introducción: Series Temporales

Series Temporales Parcialmente Observadas



I. Objetivos del Trabajo

Pregunta de investigación:

¿En qué medida los diversos métodos de imputación pueden recuperar eficazmente valores faltantes? ¿Y Transformer?

Principal: Estudio de Modelos Transformer para imputar series temporales.

Específicos:


- Análisis del Estado del Arte
- Fundamentación Matemática.
- Desarrollo del Pipeline y Paquete Python.
- Evaluación del Rendimiento.



I. El Problema de la Imputación

$$\hat{\chi}^{\text{test}} = f(\chi_{\text{missing}}^{\text{test}}, \mathbf{M}^{\text{test}})$$

Comparación de Imputación para PM10
Rango: 2023-03-03 00:00:00 a 2023-03-10 00:00:00



$\mathbf{M}^{\text{test}}$

Máscara binaria que indica con 1s donde se eliminaron valores artificialmente y 0s donde hay valores observados o faltantes naturales.

I. Evaluación.

La eliminación artificial permite comparar los valores imputados con su valor verdadero (ground truth) mediante diversas métricas de error:

$$\text{Error} = \text{Metric}(\hat{\mathcal{X}}^{\text{test}}, \mathcal{X}_{\text{orig}}^{\text{test}}, \mathbf{M}_{\text{artificial}}^{\text{test}})$$

$$\text{MAE}(\hat{\mathcal{X}}, \mathcal{X}_{\text{ori}}, \mathbf{M}_{\text{artificial}}) = \frac{|||\hat{\mathcal{X}} - \mathcal{X}_{\text{ori}}| \odot \mathbf{M}_{\text{artificial}}||_1}{||\mathbf{M}_{\text{artificial}}||_1}$$

$$\text{RMSE}(\hat{\mathcal{X}}, \mathcal{X}_{\text{ori}}, \mathbf{M}_{\text{artificial}}) = \sqrt{\frac{||(\hat{\mathcal{X}} - \mathcal{X}_{\text{ori}})^{\odot 2} \odot \mathbf{M}_{\text{artificial}}||_1}{||\mathbf{M}_{\text{artificial}}||_1}}$$

$$\text{MRE}(\hat{\mathcal{X}}, \mathcal{X}_{\text{ori}}, \mathbf{M}_{\text{artificial}}) = \frac{|||\hat{\mathcal{X}} - \mathcal{X}_{\text{ori}}| \odot \mathbf{M}_{\text{artificial}}||_1}{|||\mathcal{X}_{\text{ori}}| \odot \mathbf{M}_{\text{artificial}} + \epsilon||_1}$$

$$\text{MSE} = \text{RMSE}^2$$

II. Estado del Arte.

Taxonomía de Métodos de Imputación

$$\hat{x}_t = f(x_t, M_{\text{missing}})$$

Clasificación	Método
Estacionarios	Media, Mediana
Con Información Local	Forward Fill, Backward Fill, Interpolación Lineal.
Modelos:	
• Basados en Matrices	Hankel
• Deep Learning (Recurrentes)	RNN (LSTM), GRU
• Deep Learning (Con Atención)	Transformers, SAITS


II. Taxonomía. Estacionarios

Media

$$\hat{x}_t = \frac{1}{|X_{\text{missing}}|} \sum_{x_i \in X_{\text{missing}}} x_i$$

Mediana

$$\hat{x}_t = \text{mediana}(X_{\text{missing}})$$




Stationary series

II. Taxonomía. Información Local

Forward Fill o LOCF

$$\hat{x}_t = \begin{cases} x_{t_0} & \text{si } \{\tau \mid \tau < t \text{ y } x_\tau \neq \text{NaN}\} \text{ no es vacío} \\ 0 & \text{en caso contrario} \end{cases}$$


$$t_0 = \max\{\tau \in \{1, \dots, T\} \mid \tau < t \text{ y } x_\tau \neq \text{NaN}\}$$



Backward Fill o NOCB

$$\hat{x}_t = \begin{cases} x_{t_1} & \text{si } \{\tau \mid \tau > t \text{ y } x_\tau \neq \text{NaN}\} \text{ no es vacío} \\ 0 & \text{en caso contrario} \end{cases}$$


$$t_1 = \min\{\tau \in \{1, \dots, T\} \mid \tau > t \text{ y } x_\tau \neq \text{NaN}\}$$



II. Taxonomía. Información Local.

Interpolación Lineal

$$\hat{x}_t = x_{t_a} + (x_{t_b} - x_{t_a}) \frac{t - t_a}{t_b - t_a}$$



II. Taxonomía. Basados en Matrices: Hankel Imputation

Serie Temporal $x(1), \dots, x(n) \in \mathbb{R}^d$


$$H = \begin{pmatrix} x(1) & x(2) & \cdots & x(k) \\ x(2) & x(3) & \cdots & x(k+1) \\ \vdots & \vdots & \ddots & \vdots \\ x(n-k+1) & x(n-k+2) & \cdots & x(n) \end{pmatrix}$$

$(n-k+1) \times (kd)$


$$\min_X \|X\|_* \quad \text{s.t.} \quad X(i, j) = M(i, j) \quad \forall (i, j) \in \Omega$$

$\|\cdot\|_*$: Norma nuclear, suma valores singulares

III. Del Machine Learning al Deep Learning



Perceptrón



MLP: Perceptrón Multicapa

FFNN: Feed Forward Neural Network



Otros modelos:

RNN (LSTM)

IV. Arquitectura del Transformer

Attention is All You Need. (Vaswani et al., 2017)

Conocido por su aplicación al campo del NLP.




IV. Arquitectura del Transformer:

Positional Encoding

- Input Embedding
- Positional Encodings

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$
$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$



IV. Arquitectura del Transformer:

Mecanismo de Atención

Construye **Q** (Query), **K** (Key), **V** (Value).


Idea clave: Scaled Dot-Product Attention.

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

$$[\text{softmax}(\mathbf{z})]_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} = \frac{e^{z_i - m}}{\sum_{j=1}^K e^{z_j - m}}$$

Apunte sobre la estabilidad numérica del softmax

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$



IV. Arquitectura del Transformer:

Componentes Finales

Conexiones Residuales: Facilitan flujo de gradientes.

Normalización de Capas: Estabiliza entrenamiento

$$\text{Add\&Norm}(x) = \text{LayerNorm}(\text{Add}(x))$$


$$\text{Add}(x) = x + \text{SubLayer}(x)$$

$$\text{LayerNorm}(\mathbf{z}) = \gamma \odot \frac{\mathbf{z} - \boldsymbol{\mu}_{\text{vec}}}{\sqrt{\boldsymbol{\sigma}_{\text{vec}}^2 + \epsilon}} + \boldsymbol{\beta}$$

$$\text{FFNN}(\mathbf{x}) = \text{ReLU}(\mathbf{x}W_1 + \mathbf{b}_1)W_2 + \mathbf{b}_2$$

$$\text{Linear}(x) = xW + b$$


$$P(y_i) = \text{softmax}(xW + b) = \frac{\exp(\text{logits}_i)}{\sum_j \exp(\text{logits}_j)}$$



IV. SAITS: Self-Attention Based Imputation for Time Series.

Arquitectura General.

Modelo de DL
especializado en
imputación de
series temporales.
(Du et Al., 2023)




IV. SAITS: Self-Attention Based Imputation for Time Series. Mecanismo DMSA.

$$\text{DiagMaskedSelfAttention}(Q, K, V) = \text{softmax} \left(\text{DiagMask} \left(\frac{QK^T}{\sqrt{d_k}} \right) \right) V$$

$$[\text{DiagMask}(\mathbf{x})]_{ij} = \begin{cases} -\infty & \text{si } i = j \\ x_{ij} & \text{si } i \neq j \end{cases}$$

$$[\text{softmax}(\mathbf{z})]_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} = \frac{e^{z_i - m}}{\sum_{j=1}^K e^{z_j - m}}$$

$$\begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix} \Rightarrow \text{DiagMask} \Rightarrow \begin{bmatrix} -\infty & b & c \\ d & -\infty & f \\ g & h & -\infty \end{bmatrix} \xrightarrow{\text{softmax fila a fila}} \begin{bmatrix} 0 & \alpha & 1 - \alpha \\ \beta & 0 & 1 - \beta \\ \gamma & 1 - \gamma & 0 \end{bmatrix}$$



IV. SAITS: Self-Attention Based Imputation for Time Series.

Flujo de Transformaciones Matemáticas.

1st DMSA block output: X_1

$$X_1 = zW_z + b_z$$

2nd DMSA block output: X_2


$$X_2 = \text{ReLU}(\beta W_\beta + b_\beta) W_y + b_y$$

Weighted combination block output: X_3

$$X_3 = (1 - \eta) \odot X_1 + \eta \odot X_2$$

Imputed Data

$$\hat{X}_c = M \odot X + (1 - M) \odot X_3$$



V. PyPOTS: Una biblioteca de Python para trabajar con Series Temporales Parcialmente Observadas

SAITS: SELF-ATTENTION-BASED IMPUTATION FOR TIME SERIES *

A PREPRINT

Wenjie Du [†]
Concordia University
Montréal, Canada
wenjay.du@gmail.com

David Cote
Ciena Corporation
Ottawa, Canada
dcote@ciena.com

Yan Liu
Concordia University
Montréal, Canada
yan.liu@concordia.ca


July 6, 2023

ABSTRACT

Missing data in time series is a pervasive problem that puts obstacles in the way of advanced analysis. A popular solution is imputation, where the fundamental challenge is to determine what values should be filled in. This paper proposes SAITS, a novel method based on the self-attention mechanism for missing value imputation in multivariate time series. Trained by a joint-optimization approach, SAITS learns missing values from a weighted combination of two diagonally-masked self-attention (DMSA) blocks. DMSA explicitly captures both the temporal dependencies and feature correlations between time steps, which improves imputation accuracy and training speed. Meanwhile, the weighted-combination design enables SAITS to dynamically assign weights to the learned representations from two DMSA blocks according to the attention map and the missingness information. Extensive experiments quantitatively and qualitatively demonstrate that SAITS outperforms the state-of-the-art methods on the time-series imputation task efficiently and reveal SAITS' potential to improve the learning performance of pattern recognition models on incomplete time-series data from the real world. The code is open source on GitHub at <https://github.com/WenjieDu/SAITS>.

Keywords Time Series · Missing Values · Imputation Model · Self-Attention · Neural Network

- Implementa Transformer
- Implementa SAITS
- Basada en PyTorch



V. Desarrollo de Software

Se desarrolló el paquete Python **pampaneira_imputation**, que consta de los siguientes módulos:

- **data_loader.py**: Carga de conjuntos de datos. Utiliza pandas.
- **data_preprocessor.py**: Preprocesamiento de datos. Se realizó una división 80/20 entre datos de entrenamiento y prueba, donde el 80% de entrenamiento se subdivide en training (80%) y validación (20%).
- **imputation_methods.py**: Implementación de todos los métodos de la taxonomía. Uso del Transformer y SAITS de PyPOTS.
- **evaluation.py**: Elaboración de tablas con las métricas de evaluación
- **utils.py**: Funciones auxiliares y utilidades
- **config.py**: Configuraciones y parámetros: `d_model=128`, `n_heads=4`, `d_k=32`, `d_v=32`, `epochs=50`.

<https://github.com/eigenric/TFG>

V. Flujo de Trabajo. Pipeline

Notebook_imputation.ipynb

Flujo de Trabajo de Imputación de Contaminación para Pampane

1. Configuración e Importaciones

2. Carga de Datos

3. Preprocesamiento de Datos

3.1 Rellenar Marcas de Tiempo Faltantes (Dentro de Perio.

3.2 Dividir en Periodos

3.4 Dividir, Escalar, Ventanear y Crear Ausencia para el Pe

3.4 Dividir, Escalar, Ventanear y Crear Ausencia para el Pe

Fechas de división del periodo 2 (20 días)

4. Métodos de Imputación para Periodo 1

4.1. Modelos Baseline

4.2 Imputación por Media

4.3 Interpolación Lineal

4.4 Relleno Forward/Backward (ffill/bfill)

Hankel Imputation

4.5. Modelo Transformer

4.6. Modelo SAITS

4.2. Tiempos de ejecución en Periodo 1

6. Evaluar Resultados de Imputación en Periodo 1

6.1. Interpretación de la Tabla de Métricas de Imputación/..

7. Evaluar Resultados de Imputación en Periodo 2

8. Visualizar Resultados (Ejemplo: NO2)

9. Opcional: Guardar Resultados

```
[11]: df_int_reindexed[config.INTERSECTION_POLLUTION_COLS + config.PAM_BUB_TRAFFIC_C
```

```
[11]:
```



	CO	NO2	NO	O3	PM10	eBC_ff	eBC_bb	TEMP	RH	WS	...
2023-01-18 00:00:00+00:00	0.19	1.1	0.1	NaN	0.0	NaN	NaN	6.6	52.9	3.89	...
2023-01-18 01:00:00+00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...
2023-01-18 02:00:00+00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...
2023-01-18 03:00:00+00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...
2023-01-18 04:00:00+00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...
...	...	...	...	...	...	...	...	...	...	...	...
2023-06-26 19:00:00+00:00	0.26	8.8	1.5	111.4	7.8	0.6	0.1	31.4	21.5	1.12	...
2023-06-26 20:00:00+00:00	0.27	3.9	0.4	99.6	23.0	0.3	0.1	28.8	26.0	0.81	...
2023-06-26 21:00:00+00:00	0.26	5.1	0.1	78.8	11.3	0.4	0.1	25.7	29.5	1.06	...
2023-06-26 22:00:00+00:00	0.26	5.8	0.1	77.4	1.9	0.2	0.1	24.7	27.9	1.25	...
2023-06-26 23:00:00+00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...

3840 rows x 114 columns

V. Flujo de Trabajo. Preprocesamiento

Escalado:
$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$


Ventana Deslizante:





$$N_{\text{windows}} = N_{\text{rows}} - 24 + 1$$

I. Introducción: Series Temporales

Series Temporales Parcialmente Observadas



VI. Visualización PM10. Patrón 'Point', 'Subseq'. Periodo 1




VI. Resultados Evaluación: Periodo 1

Cuadro 2: Resultados de Evaluación - Periodo 1 (10 % ausencia, patrón 'point')

Métrica	Median	Mean	Linear	Ffill	Bfill	Hankel	Transformer	Saits
RMSE	1,1342	1,0521	0,8796	1,0604	1,0487	0,8071	0,6488	0,6360
MSE	1,2865	1,1069	0,7737	1,1244	1,0997	0,6514	0,4209	0,4045
MAE	0,6910	0,7346	0,4621	0,5618	0,5554	0,5432	0,3422	0,3263
MRE	0,9311	0,9898	0,6226	0,7569	0,7484	0,7319	0,4611	0,4397


VI. Resultados Evaluación: Periodo 1



- Interpolación Lineal: Mejor método simple.
- DL (SAITS/Transformer) claramente superior.
- SAITS lidera en precisión.


VI. Comparativa de porcentajes y patrones de ausencia

Patrón Puntual ('Point')



- 10% ausencia es el de menor error.

Patrón Ráfaga ('Subseq')



- Ligero incremento del error respecto al mismo % puntual.

VII. Conclusión Final:

A la pregunta de investigación planteada inicialmente:

“¿En qué medida los métodos de imputación pueden recuperar eficazmente los valores faltantes? ¿Y Transformer?”

Podemos responder:

VII. Conclusión Final:

A la pregunta de investigación planteada inicialmente:

“¿En qué medida los métodos de imputación pueden recuperar eficazmente los valores faltantes? ¿Y Transformer?”

Podemos responder:

1. La eliminación artificial nos ha permitido comparar **los valores imputados con los originales (ground truth)** mediante métricas de evaluación (RMSE, MRE, etc.).

VII. Conclusión Final:

A la pregunta de investigación planteada inicialmente:

“¿En qué medida los métodos de imputación pueden recuperar eficazmente los valores faltantes? ¿Y Transformer?”

Podemos responder:

1. La eliminación artificial nos ha permitido comparar **los valores imputados con los originales (ground truth)** mediante métricas de evaluación (RMSE, MRE, etc.).
2. **Transformer y SAITS son claramente superiores**, según estas métricas, a los demás modelos. Se han estudiado sus arquitecturas en profundidad.

VII. Conclusión Final:

A la pregunta de investigación planteada inicialmente:

“¿En qué medida los métodos de imputación pueden recuperar eficazmente los valores faltantes? ¿Y Transformer?”

Podemos responder:

1. La eliminación artificial nos ha permitido comparar **los valores imputados con los originales (ground truth)** mediante métricas de evaluación (RMSE, MRE, etc.).
2. **Transformer y SAITS son claramente superiores**, según estas métricas, a los demás modelos. Se han estudiado sus arquitecturas en profundidad.
3. **SAITS mejora ligeramente** a Transformer.

VII. Conclusión Final:

A la pregunta de investigación planteada inicialmente:

“¿En qué medida los métodos de imputación pueden recuperar eficazmente los valores faltantes? ¿Y Transformer?”

Podemos responder:

1. La eliminación artificial nos ha permitido comparar **los valores imputados con los originales (ground truth)** mediante métricas de evaluación (RMSE, MRE, etc.).
2. **Transformer y SAITS son claramente superiores**, según estas métricas, a los demás modelos. Se han estudiado sus arquitecturas en profundidad.
3. **SAITS mejora ligeramente** a Transformer.
4. Aunque la ausencia por ráfagas da mayor error que la puntual, modela los fallos de los sensores de forma más realista.

VII. Conclusión Final:

A la pregunta de investigación planteada inicialmente:

“¿En qué medida los métodos de imputación pueden recuperar eficazmente los valores faltantes? ¿Y Transformer?”

Podemos responder:

1. La eliminación artificial nos ha permitido comparar **los valores imputados con los originales (ground truth)** mediante métricas de evaluación (RMSE, MRE, etc.).
2. **Transformer y SAITS son claramente superiores**, según estas métricas, a los demás modelos. Se han estudiado sus arquitecturas en profundidad.
3. **SAITS mejora ligeramente** a Transformer.
4. Aunque la ausencia por ráfagas da mayor error que la puntual, modela los fallos de los sensores de forma más realista.

Así, estas series temporales, ya completadas, pueden utilizarse para mejorar el estudio de la **sostenibilidad ambiental**, de acuerdo con los ODS.

¡Gracias por su *Attention!*

<https://github.com/eigenric/TFG>